


O que determina o sucesso ou o fracasso de um livro?

Análise
Exploratória de
Dados,
detecção de
Outliers e
detalhamento

Cleber Santos
14 de julho de
2026

Introdução

- Base de Dados: Goodreads (Extraída via web scraping da API oficial a partir de 25 de maio de 2019).
- Volume de Dados: 11.121 registros após a etapa de limpeza e tratamento de outliers.
- Objetivo: Identificar as variáveis que compõem os fatores determinantes para a avaliação e recepção de um livro.
- (O link da base de dados estará disponível ao final da apresentação).



Primeiras Análises

Começamos com as observações no padrão do dataset


Um ponto em comum para várias métricas para esse dataset é olhar a quantidade de avaliações que cada livro tem e o quanto são dispersos esses números para cada livro. Então olhamos a dispersão nas avaliações primeiro.

O objetivo é encontrar quais variáveis evidenciam o sucesso e o fracasso de um livro no goodreads.

Quantidade de avaliações	
Média	17 945.12
Desvio padrão	112 509.12
Menor quantidade	0
25%	104
50%	745
75%	4 996
Maior quantidade	4 597 666

Avaliações abaixo de 5000

Como visto no anterior, o desvio padrão nas avaliações é muito alto. Temos um grande número de livros com mais de 10.000 avaliações, enquanto outros tem 5 ou até zero avaliações no Goodreads. O problema que isso gera é que livros com poucas avaliações parecem melhores que livros com mais avaliações.



Na tabela temos quatro exemplos bem distintos. Os títulos 1 e 2 não possuem número relevante de avaliações, mas possuem notas acima de livros já renomados e conhecidos (3 e 4) que contam com mais de 30 mil avaliações cada. Por isso, para desenvolver e testar qualquer métrica, o parâmetro mínimo são as avaliações.

Comparativo de livros baseado em avaliações					
	Título	Autores	Média Av.	Avaliações	Av. Texto
1	Comoediae 1	Aristophanes/F. W. Hall/W.M. Geldart	5,00	0	0
2	Willem de Kooning: Late Paintings	Julie Sylvester/David Sylvester	5,00	1	0
3	Harry Potter Boxed Set Books 1-5	J.K. Rowling/Mary GrandPré	4,78	41428	164
4	The Complete Calvin and Hobbes	Bill Watterson	4,82	32213	930

É por isso que o parâmetro mínimo para outras métricas será o de 100 avaliações no mínimo.

O Piso Estatístico

2.4

Nota Mínima Detectada
(Filtro ≥ 100 avaliações)




Análise do limite inferior

Ao aplicar o filtro de significância estatística (a avaliação de pelo menos 100 pessoas, que representam o segundo, terceiro e último quartil), é possível perceber que a nota mínima dentro dessa restrição é 2.4.

Livros com notas inferiores a esta, não possuem volume de dados suficiente para serem considerados relevantes na análise de padrões consistentes de mercado.

O livro que demarca essa nota mínima é ***Citizen Girl*** das autoras Emma McLaughlin e Nicola Kraus.

Raio-x



isbn:

0743266862

Num. de páginas:
305

Quantidade de reviews:
5415

Reviews em texto:
577

Publicação:
04/10/2005

Editora: Washington Square Press

1 Problema Principal

O livro foi o exemplo perfeito de expectativa vs realidade. Veio logo após o case de sucesso: The Nanny Diaries

2 Reclamações

A maior parte das reclamações é sobre ele ter pouco ou nenhum conteúdo relevante sendo "comercial demais".

3 Forma de Escrita


Algo muito criticado, foi o fato de não dar nome ou características aos personagens. Como chamá-los de Girl, Guy a fim de colocar o próprio leitor a perceber posições como um RPG, onde você é o personagem. Essa mesma forma de escrita é exatamente o que muitos dos 14% de avaliações entre 4 e 5 estrelas elogiaram.

4 Sobre a História

Em resumo o livro fala sobre a dificuldade de uma mulher jovem e recém formada em lutar não somente no mercado como com o próprio sistema, além de suas relações com todo esse contexto envolvido.

Existe um padrão entre esses e outros livros abaixo nas notas, o choque de expectativa e livros muito antigos mal adaptados ao tempo como The Governess e outros.

E então os 5 livros com as piores notas dentro do mínimo de avaliações



1

Citizen Girl, por Emma McLaughlin/Nicola Kraus

• Nota: 2,4

2

The Governess, por Sarah Fielding /Candace Ward

• Nota: 2,63

3

Alentejo Blue, por Monica Ali

• Nota: 2,72

4

Yellow Dog, por Martin Amis

• Nota: 2,79

5

You Don't Love Me Yet, por Jonathan Lethem

• Nota: 2,81

Por outro lado, ter uma quantidade de avaliações muito alta, às vezes pode mascarar outros filtros, se considerarmos que mais de 4 milhões de avaliações manter uma nota acima de 4,5 é quase impossível. Então vamos observar primeiro os livros do último quartil, ou seja, livros com mais de 4 996 avaliações.

Comparativo de livros baseado em avaliações					
	Título	Autores	Média Av.	Avaliações	Av. Texto
1	The Complete Calvin and Hobbes	Bill Watterson	4,82	32213	930
2	Harry Potter Boxed Set Books 1-5	J.K. Rowling/Mary GrandPré	4,78	41428	164
3	It's a Magical World (Calvin and Hobbes #11)	Bill Watterson	4,76	23875	303
4	The Days Are Just Packed	Bill Watterson	4,69	20308	244

Livros com nota maior que 4 e número de avaliações acima de 4 996 (último quartil)

Análise de variáveis

Observando o comportamento da coluna número de páginas, é fácil perceber que ela não possui um padrão que influencie nas notas ou até mesmo na popularidade. Temos livros com 200 e outros com 12 páginas com nota acima de 4. Não é a variável que procuramos.

A quantidade de avaliações em texto também não altera o comportamento do que Média de avaliações e Total de avaliações fazem. O idioma também não seria um fator a se considerar, o site é estadunidense então logicamente livros em inglês terão melhores notas e maior volume de avaliações. Como páginas e idiomas não explicam o sucesso, precisamos olhar para quem distribui essas obras: As Editoras.

Quantidade de Páginas

Média	396,76
Desvio padrão	267,39
Menor quantidade	9,00
25%	224,00
50%	348,00
75%	481,00
Maior quantidade	3.342,00

Análise por Editoras

Também percebemos que a Editora pode ser um fator a influenciar, uma vez que editoras famosas tem notas mínimas mais altas. Então dividimos as editoras em dois tipos nas tabelas abaixo: maior volume e maior nota de avaliações. E então veja os Best-Sellers de cada tipo.

Encontramos evidências de que a nota média deve ser interpretada de forma relativa ao volume de avaliações. Embora haja uma diferença de aproximadamente 1 ponto nas notas brutas entre os casos analisados, o volume do grupo de maior engajamento chega a ser 100 vezes superior.

Best-Seller por volume de avaliações				
Editora	Título	Autor	Nota Média	Total de Avaliações
Penguin	Lord of the Flies	William Golding	3,68	2,03 M
Scholastic	Harry Potter and the Prisoner of Azkaban	J.K. Rowling/Mary GrandPré	4,56	2,3 M
Harper Collins	The Alchemist	Paulo Coelho/Alan R. Clarke	3,86	1,6 M

Best-Seller por nota média				
Editora	Título	Autor	Nota Média	Total de Avaliações
Andrews McMeel Publishing	The Calvin and Hobbes Tenth Anniversary Book	Bill Watterson	4,63	49.122
Banner of Truth	The Valley of Vision: A Collection of Puritan	Arthur Bennett	4,54	9.476
Crossing Press	Sister Outsider: Essays and Speeches	Audre Lorde	4,49	12.105

Normalização de quantidade de avaliações

Não há consistência em comparar um livro com mais de 2 milhões de avaliações com um livro contendo apenas 10 mil apenas de forma bruta entre as variáveis. No entanto uma forma de fazer essa comparação, tratando essa disparidade de escala usaremos uma métrica de padronização chamada Média Ponderada Bayesiana.

- A Média Bayesiana recalcula as notas usando como constante o valor do primeiro quartil dos livros já setados anteriormente como os de relevância (**acima de 100**). Isso evita que livros com baixo número de avaliações fiquem no topo de forma injusta e distorçam o ranking.
- Livros com milhões de avaliações, como Harry Potter, mantêm suas notas praticamente intactas (**4.57**). O modelo reconhece que o volume massivo de leitores dá certeza total sobre a qualidade do livro.
- Ajuste de Livros Menores: Obras com notas muito altas, mas com menos engajamento (**como o Study Bible, que tem 4 mil avaliações**), têm suas notas levemente ajustadas para baixo (**4.70 para 4.63**) até acumularem mais dados.

Best-Seller por volume de avaliações			
Média Bayes	Título	Nota Média	Total de Avaliações
4,81	The Complete Calvin and Hobbes	4,82	32.213
4,77	Harry Potter Boxed Set Books	4,78	41.428
4,75	It's a Magical World	4,76	23.875
4,70	Homicidal Psycho Jungle Cat	4,72	15.365
4,67	The Days Are Just Packed	4,69	20.308
4,63	The Absolute Sandman	4,65	15.640
4,63	Study Bible: NIV	4,70	4.166
4,63	Sunday Pages 1985: Calvin and Hobbes	4,71	72.451
4,59	J.R.R. Tolkien Box Set: The Hobbit/The Lord of the Rings	4,59	101.233
4,57	Harry Potter and the Half-Blood Prince	4,57	2.095.690

Por fim, o objetivo era avaliar o sucesso de um livro. Para isso foi preciso encontrar as variáveis que influenciavam esse status e identificar os livros que estão no espectro oposto do objetivo. E assim foi possível concluir que as variáveis determinantes são: **Média de avaliações**, **Número de avaliações** (com um piso **mínimo de relevância**), a **Editora** e a coluna recém adicionada: **Média Bayes** que é quem equipara o volume de avaliações e nota média. Os próximos passos serão utilizar essas variáveis para **Clusterização** e a criação de uma **Árvore de Decisão** que sirva para destacar entre as variáveis quem tem mais potencial de mudar a direção em que um livro caminha no sentido de ser bem quisto ou não pelo público.

Contatos e repositório com a análise completa:

-  • <https://www.linkedin.com/in/cleber-xcl-esc/>
-  • https://github.com/xcl-esc/Analise_Goodreads
-  • https://drive.google.com/drive/folders/1vuiPK3cBw2QLcsR7BUffP0kiOkPwbBRfusp=drive_link